Universidad Icesi, Facultad Barberi de Ingeniería Diseño y Ciencias Aplicadas - Maestría en Inteligencia Artificial Aplicada (MIAA)

Clasificación de alteraciones visibles en hojas de café mediante aprendizaje automático

Victor Manuel Hurtado Lopez, Dora Valencia Martínez, Giovanni Jaramillo Bolaños, Camilo Percy
victor.hurtado@u.icesi.edu.co, dora.valencia@u.icesi.edu.co, giovanni.jaramillo@u.icesi.edu.co,camilo.percy13238@u.icesi.edu.co

Resumen - Este proyecto aborda la dificultad de obtener una orientación preliminar consistente sobre alteraciones visibles en hojas de café a partir de fotografías. En esta primera etapa se delimita el problema, se formulan los objetivos y se revisan antecedentes de clasificación de imágenes, con atención a las condiciones de captura y a las diferencias entre conjuntos de datos. El trabajo seguirá la metodología CRISP-DM y comenzará con RoCoLe, un conjunto de fotografías de café robusta tomadas en campo y etiquetadas según el estado de la hoja y los niveles de severidad de roya. Se estudiarán las categorías disponibles, la calidad y distribución de las imágenes, y se compararán métodos de clasificación bajo un mismo esquema de evaluación. RoCoLe será el conjunto principal de modelado y evaluación. El subconjunto recuperado de BRACOL se incluirá en la caracterización de datos y en un análisis exploratorio separado, limitado a las imágenes y etiquetas que cumplan los criterios de integridad y compatibilidad definidos. El resultado esperado es un prototipo que oriente la revisión de una hoja individual dentro de las categorías estudiadas y comunique sus límites ante condiciones no representadas. Esta primera entrega presenta la fundamentación y la planeación del estudio; aún no reporta resultados experimentales.

Índice de Términos - Aprendizaje automático, café, clasificación de imágenes, enfermedades foliares.

I. Introducción

El café es uno de los cultivos de mayor relevancia a nivel mundial y Colombia tiene una importante participación en su producción [3]. Según estimaciones del equipo económico de la Federación Nacional de Cafeteros, divulgadas en febrero de 2026, el sector cafetero representa cerca del 20,7 % de la economía agropecuaria y del 1,8 % del Producto Interno Bruto (PIB) nacional [8]. En 2025, la producción nacional alcanzó los 13,7 millones de sacos de 60 kg de café verde, mientras que las exportaciones se ubicaron en 13,14 millones de sacos, registrando un incremento del 6,6% respecto al año anterior [3].

Pese a esa importancia económica, la productividad enfrenta amenazas fitosanitarias como la roya (Hemileia vastatrix). Hoy la detección depende en gran medida de inspecciones manuales en campo, que requieren tiempo y experiencia [4].

II. Planteamiento del problema

En el crecimiento del cultivo, los caficultores pueden notar cambios extraños en las hojas, opacidad**,** deterioro u otras alteracione**s** y pueden recurrir a su experiencia para interpretar lo que observan. Esta interpretación puede resultar difícil cuando no se reconoce con certeza qué es lo que se observa ni cuándo conviene pedir una revisión técnica.

Al caficultor puede costarle interpretar lo que observa en una hoja por las condiciones de observación. Según la hora del día, la luz del sol puede hacer que la misma hoja se vea distinta y oculte o confunda lo que realmente ocurre. Además, una fotografía no siempre permite observar la hoja desde varios ángulos: por arriba puede parecer sana y por abajo aparecer alteraciones. Si la alteración no se reconoce oportunamente, puede retrasarse la búsqueda de información o de una revisión técnica. La imagen por sí sola puede no ser suficiente para distinguir una enfermedad, suciedad o una plaga.

En este proyecto se busca brindar a los caficultores una orientación preliminar a partir de una foto de una hoja individual, para apoyar el reconocimiento de las categorías estudiadas y orientar una posible revisión técnica. No se trata de sustituir la experiencia ni de emitir un veredicto final: es un apoyo técnico que complementa lo que ya saben, para que tomen mejores decisiones incluida la de pedir revisión técnica cuando convenga.

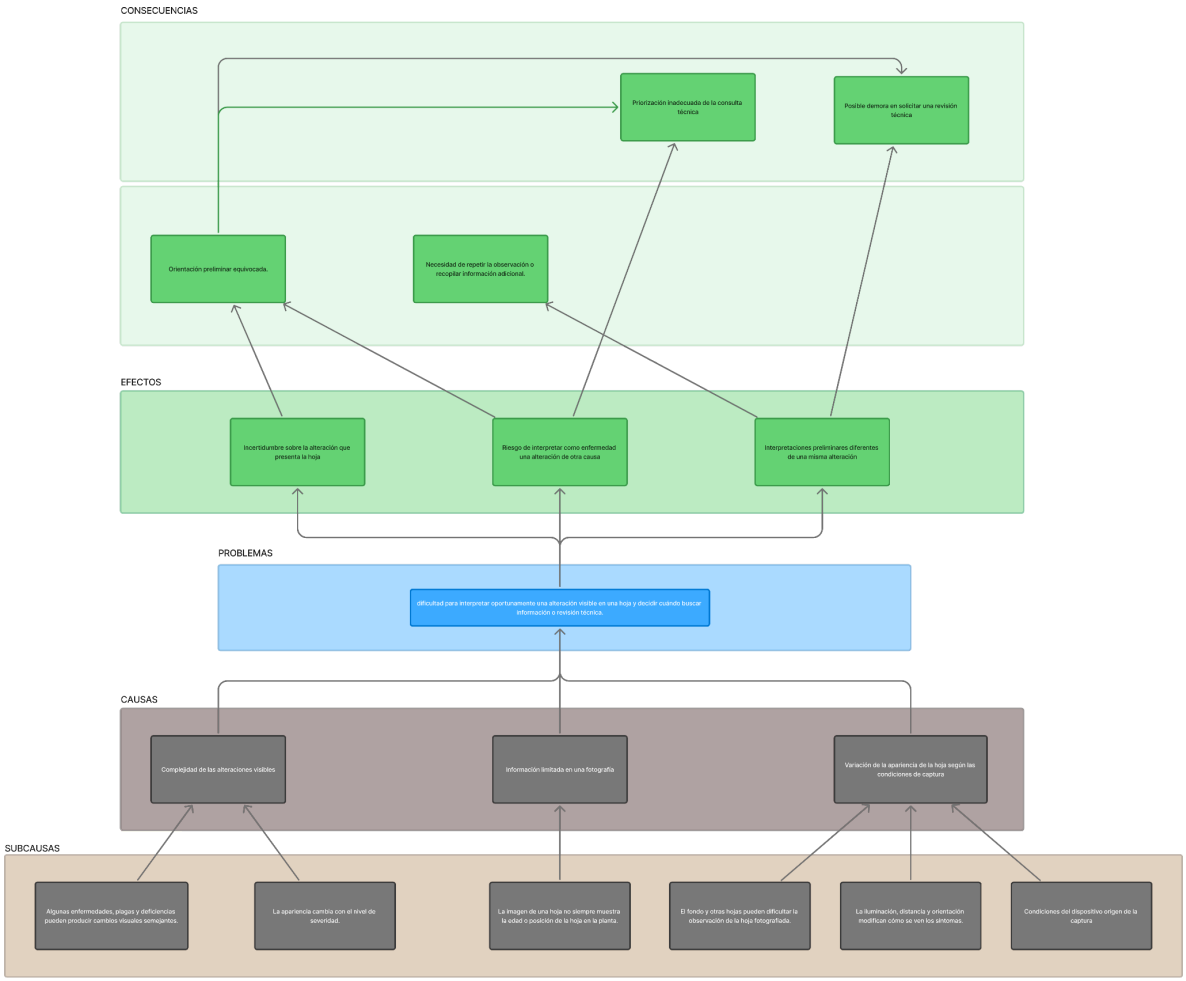


Fig. 1. Árbol de problemas del proyecto. Fuente: elaboración propia. Las relaciones propuestas son un marco de análisis, no resultados de validación con productores.

Para el alcance experimental del proyecto, el problema central del árbol se delimita a la dificultad para interpretar de manera consistente las alteraciones visibles en una hoja de café a partir de una fotografía. La consulta técnica se considera una utilidad potencial del apoyo, cuyo efecto no se evaluará en este estudio.

Como complemento de las consecuencias de la figura 1, una orientación preliminar equivocada podría ocasionar gastos de manejo no pertinente si influye en una decisión de manejo; repetir la observación podría implicar costos adicionales de tiempo y revisión; y una demora en solicitar revisión técnica podría contribuir a pérdidas productivas y económicas si una afección perjudicial avanza sin atención oportuna. Estas relaciones se plantean como consecuencias económicas potenciales que conectan el árbol con la relevancia del problema expuesta en la introducción. No representan pérdidas medidas por el equipo ni implican que el prototipo vaya a reducirlas. El alcance experimental se mantiene en la clasificación de imágenes y la evaluación del modelo.

III. Objetivos

Objetivo general. evaluar un modelo de aprendizaje automático para clasificar alteraciones visibles en hojas de café a partir de imágenes individuales, utilizando el conjunto de datos RoCoLe y BRACOL, analizando su desempeño, errores y limitaciones mediante un notebook experimental, con fecha de finalización en noviembre de 2026..

Objetivos específicos.
1. **Caracterizar y preparar** el conjunto de datos RoCoLe y BRACOL mediante el análisis de la distribución de sus categorías, la calidad de las imágenes y la organización de los datos, con el fin de establecer una base confiable y reproducible para el entrenamiento y la evaluación de los modelos.
2 .**Implementar y comparar** al menos dos modelos de clasificación de imágenes utilizando un protocolo de evaluación común, para seleccionar el de mejor desempeño según el F1 macro y analizar sus resultados mediante métricas de clasificación, matrices de confusión y revisión de errores.
3. **Integrar y validar** el modelo seleccionado en un notebook ejecutable que permita clasificar imágenes individuales de hojas de café, verificando su funcionamiento mediante imágenes reservadas de cada categoría y documentando las predicciones, los posibles errores y las limitaciones del sistema.

La siguiente tabla vincula los objetivos con sus evidencias de cumplimiento y los hitos del cronograma. Las métricas permitirán evaluar los resultados sin fijar de antemano un valor mínimo de desempeño predictivo.

Objetivo	**Indicadores y evidencias**	**Plazo previsto**
General	Evaluación documentada y evidencias de los tres objetivos específicos, incluida la demostración en el notebook.	25/11/2026 (T16)
Específico 1	Inventarios de RoCoLe y BRACOL recuperado: conteos por categoría, faltantes, duplicados y exclusiones; diccionario de etiquetas y particiones reproducibles de RoCoLe.	31/10/2026 (T06)
Específico 2	Al menos dos modelos comparados en RoCoLe; evaluación final reservada con exactitud, F1 macro, sensibilidad por categoría y matriz de confusión. Análisis de errores y reporte exploratorio separado del subconjunto compatible de BRACOL, con sus exclusiones y límites.	17/11/2026: selección (T11). 20/11/2026: resultados (T12).
Específico 3	Al menos una imagen reservada por categoría; número de pruebas y proporción de ejecuciones completas; comprobación de que se presentan la predicción y las limitaciones. Registro de pruebas del notebook.	22/11/2026 (T14)

Completar el flujo sin errores de ejecución no equivale a acertar la clasificación; el desempeño predictivo se medirá en la evaluación del objetivo específico 2.

IV. Estado del arte

En la planeación de este estudio, se consideraron dos conjuntos de imágenes que permiten analizar las alteraciones en hojas de café las cuales son relevantes a la hora de abordar un problema de clasificación y al momento de evaluar modelos. RoCoLe, como primer conjunto contiene alrededor de 1.560 imágenes, fotografías de hojas de café robusta, tomadas directamente en ambiente natural con un teléfono móvil [7]. Por otra parte, BRACOL reúne cerca de 1.747 imágenes de hojas de café arábica, tanto sanas como afectadas por distintos tipos de estrés biótico; las fotografías de este conjunto fueron tomadas en un ambiente parcialmente controlado [5]. Esto permite identificar que los dos conjuntos no comprenden exactamente las mismas categorías ni condiciones. Estas distinciones son importantes y deben contemplarse antes de comparar el desempeño de los modelos. RoCoLe será el conjunto principal para desarrollar y evaluar los modelos. BRACOL es público en Mendeley Data [5]; el equipo dispone de una recuperación parcial de 1.401 imágenes y un archivo de etiquetas con 1.747 registros. Este subconjunto se incluirá en la caracterización para documentar faltantes, distribución de categorías y compatibilidad de etiquetas. Las imágenes que superen los controles de integridad y correspondan a categorías comparables se utilizarán en un análisis exploratorio separado, con el modelo seleccionado en RoCoLe, sin mezclarlas con sus datos de entrenamiento ni utilizarlas para seleccionar el modelo. Si una categoría no resulta comparable, se documentará su exclusión de ese análisis. Los resultados describirán únicamente el subconjunto utilizado y no se atribuirán exclusivamente a las condiciones de captura, pues también cambian la especie y otras características de los datos. Las categorías de RoCoLe corresponden a hoja sana, presencia de ácaro rojo y cuatro niveles de severidad de roya [7]. Durante la caracterización se decidirá si se conservan o agrupan estos niveles. Las conclusiones se limitarán a las categorías y condiciones evaluadas; el uso de imágenes de café robusta tomadas en Ecuador no demuestra por sí solo funcionamiento en cultivos colombianos.

Entre los métodos empleados en diferentes investigaciones sobre plantaciones de café, se encuentran las máquinas de soporte vectorial y las redes neuronales convolucionales [6]. También se han estudiado arquitecturas que contemplan la combinación de múltiples métodos de clasificación, tratamiento de imágenes sobre las zonas afectadas y optimización lo que incrementó la efectividad de los modelos [2]. En un estudio realizado en 2022 se encontraron diferencias de desempeño entre conjuntos de laboratorio y campo, además de identificar que el fondo puede influir en las predicciones [4].

La revisión de Motta et al. [6] no solamente estudió hojas de café sino también granos; este tipo de estudios son interesantes debido a que amplían el panorama de estudio. Aunque no es directamente comparable con el objetivo de este estudio, es una buena fuente de referencia contextual.

1. *Fusión de características para clasificar hojas de café*

   Faisal et al. estudiaron la clasificación de alteraciones en hojas de café utilizando específicamente RoCoLe. Su propuesta combina diferentes características extraídas mediante MobileNet V3 y Swin Transformer, con el propósito de reunir información antes de clasificar. En el estudio se reporta un accuracy del 84,29% para la combinación de ambos modelos, superior a la evaluación de modelos individuales [2]. Este trabajo resulta útil debido a que emplea el mismo conjunto con el que se plantea la fase inicial del proyecto. Es importante destacar que el resultado reportado en ese estudio no es directamente una meta de desempeño para el modelo propuesto en el presente estudio.

2. *Clasificación mediante atributos de textura y redes convolucionales*

   Boa Sorte et al. emplearon distintas formas de identificar hojas sanas y hojas afectadas por roya o cercospora. En una buscaron describir la textura en las hojas y en otra utilizaron una red neuronal que aprendiera patrones directamente desde la fotografía. En pruebas, se observó que la red neuronal obtuvo mejores resultados, obteniendo 0.970 en Kappa y 0.98 en sensibilidad [1]. Este trabajo es interesante debido a que propone dos caminos para abordar la problemática, sin embargo se debe analizar con detenimiento antes de tomar una decisión.

3. *Influencia de las condiciones de las fotografías*

Fenu y Malloci analizaron en su estudio cómo cambian los resultados de clasificación cuando las imágenes de hojas se toman en condiciones controladas o en ambiente completamente natural. Para ello compararon varios modelos y utilizaron distintos conjuntos de imágenes, incluido RoCoLe. Los resultados fueron mejores con las imágenes controladas que las imágenes en ambientes completamente naturales. También realizaron un experimento adicional con imágenes de RoCoLe a las que eliminaron el fondo. La exactitud promedio de tres modelos bajó de aproximadamente 85 % a 72 % [4]. Este resultado corresponde a las condiciones de ese experimento y no permite afirmar que eliminar el fondo siempre reduzca el desempeño. El apartado no precisa con claridad si los modelos fueron reentrenados después de esa transformación. Para este proyecto, este estudio muestra que la iluminación, el fondo y la forma de tomar la fotografía deben tenerse en cuenta al evaluar el modelo.

4. *Segmentación de imágenes y uso en teléfonos móviles*

Waldamichael et al. propusieron tratar las imágenes separando las hojas de los fondos e identificando las zonas afectadas a partir del color de la fotografía. Después de esta transformación utilizaron MobileNet V2 para clasificar roya, minador, cercospora y phoma. Los autores reportaron cerca de 96% de accuracy e implementaron su propuesta en dispositivos móviles, específicamente en Android [9]. Este estudio resulta relevante debido a que es un antecedente que relaciona el tratamiento de la imagen, modelos de clasificación y su empleabilidad en una aplicación móvil.

Finalmente, los estudios revisados muestran distintas alternativas para clasificar hojas de café y la importancia de considerar la calidad de las imágenes, sus condiciones de captura y el procesamiento de las zonas de interés. Es por ello que para este proyecto se propone definir previamente las categorías y el procedimiento de evaluación en RoCoLe, y comparar alternativas bajo las mismas condiciones. El aporte se concentrará en documentar el desempeño, los errores y las limitaciones del modelo seleccionado, e integrarlo en un prototipo experimental.

V. Planeación y cronograma

La planeación seguirá CRISP-DM. La primera etapa se concentra en comprender y delimitar el problema; las siguientes comprenden el análisis y la preparación de los datos, el modelado y la evaluación. La integración del modelo en un prototipo experimental permitirá presentar su salida y sus limitaciones.

Para el objetivo específico 3, el prototipo se limitará a un notebook ejecutable que permita cargar una imagen individual nueva, aplicar el procedimiento definido para el modelo entrenado y presentar la categoría predicha junto con sus limitaciones. Su alcance no incluye una aplicación móvil, un sitio web ni un despliegue en producción.

Antes de entrenar se definirán las categorías, las particiones de desarrollo y prueba y los criterios de comparación. Se revisarán duplicados y la posibilidad de agrupar las imágenes de una misma planta al separar los datos [7]. La selección del modelo se realizará con los datos de desarrollo y la prueba reservada se utilizará para la evaluación final. Se documentará la exactitud, F1 macro, la sensibilidad por categoría y la matriz de confusión.

La siguiente tabla presenta de forma legible las actividades y fechas previstas del cronograma original. Las figs. 2 y 3 se conservan como referencia de la planeación en ClickUp. Las fechas no indican que las actividades estén ejecutadas.

ID	Actividad	Fecha prevista
T01	General — Consolidar problema, alcance y objetivos; evidencia: documento coherente.	18/10/2026
T02	General — Verificar fuentes y vincular la matriz bibliográfica revisada.	18/10/2026
T03	General — Definir plan experimental, roles de RoCoLe y BRACOL, entregables y dependencias.	18/10/2026
T04	OE1 — Inventariar RoCoLe y BRACOL recuperado; registrar clases, faltantes, calidad y duplicados.	24/10/2026
T05	OE1 — Documentar etiquetas y su compatibilidad entre conjuntos, incluidos casos con varias afectaciones.	24/10/2026
T06	OE1 — Preparar particiones reproducibles de RoCoLe y un listado auditable del subconjunto de BRACOL; registrar exclusiones.	31/10/2026
T08	OE2 — Fijar métricas, dos modelos a comparar y protocolos de prueba reservada y análisis exploratorio de BRACOL.	02/11/2026
T09	OE2 — Entrenar el modelo de referencia y guardar configuración y resultados de desarrollo.	07/11/2026
T10	OE2 — Entrenar al menos un modelo adicional y comparar con la referencia bajo las mismas particiones y métricas.	13/11/2026
T11	OE2 — Analizar errores de desarrollo, seleccionar y fijar el modelo antes de evaluar la prueba reservada y BRACOL.	17/11/2026
T12	OE2 — Evaluar la prueba reservada de RoCoLe y el subconjunto compatible de BRACOL; reportar métricas, errores y límites por separado.	20/11/2026
T13	OE3 — Integrar carga de imagen, procesamiento, modelo guardado, predicción y limitaciones en el notebook.	20/11/2026

T14	OE3 — Probar al menos una imagen reservada por categoría; registrar ejecuciones completas y fallos técnicos.	22/11/2026
T15	OE3 — Documentar las pruebas del notebook y sus límites, diferenciándolos del desempeño predictivo.	24/11/2026
T16	General — Integrar evidencias de OE1–OE3, conclusiones, limitaciones y revisión final del informe.	25/11/2026

Fuente: cronograma del equipo registrado en ClickUp y archivo de actividades del proyecto. El 25/11/2026 corresponde al cierre interno previsto.

REFERENCIAS

[1] L. X. Boa Sorte, C. T. Ferraz, F. Fambrini, R. dos Reis Goulart, and J. H. Saito, “Coffee leaf disease recognition based on deep learning and texture attributes,” Procedia Computer Science, vol. 159, pp. 135–144, 2019, doi: 10.1016/j.procs.2019.09.168.

[2] M. Faisal, J.-S. Leu, and J. T. Darmawan, “Model selection of hybrid feature fusion for coffee leaf disease classification,” IEEE Access, vol. 11, pp. 62281–62291, 2023, doi: 10.1109/ACCESS.2023.3286935.

[3] Federación Nacional de Cafeteros de Colombia, “Económico.” [En línea]. Disponible en: https://federaciondecafeteros.org/eje-economico/. [Consultado: 17-oct-2026].

[4] G. Fenu and F. M. Malloci, “Evaluating impacts between laboratory and field-collected datasets for plant disease classification,” Agronomy, vol. 12, no. 10, art. no. 2359, 2022, doi: 10.3390/agronomy12102359.

[5] R. A. Krohling, G. J. M. Esgario, and J. A. Ventura, “BRACOL - A Brazilian Arabica Coffee Leaf images dataset to identification and quantification of coffee diseases and pests,” Mendeley Data, versión 1, 2019, doi: 10.17632/yy2k5y8mxg.1.

[6] I. V. C. Motta, N. Vuillerme, H.-H. Pham, and F. A. P. de Figueiredo, “Machine learning techniques for coffee classification: A comprehensive review of scientific research,” Artificial Intelligence Review, vol. 58, art. no. 15, 2025, doi: 10.1007/s10462-024-11004-w.

[7] J. Parraga-Alava, K. Cusme, A. Loor, and E. Santander, “RoCoLe: A robusta coffee leaf images dataset,” Mendeley Data, versión 2, 2019, doi: 10.17632/c5yvn32dzg.2.

[8] M. Pinzón Lemos, “El café pesa sobre 20,7% en la economía agropecuaria y 1,8% del PIB nacional,” La República, 16-feb-2026. [En línea]. Disponible en: https://www.larepublica.co/especiales/el-boom-del-agro/german-bahamon-presidente-de-fedecafe-dijo-el-cafe-pesa-sobre-20-7-en-la-economia-agropecuaria-y-1-8-del-pib-nacional-4327786. [Consultado: 17-oct-2026].

[9] F. G. Waldamichael, T. G. Debelee, and Y. M. Ayano, “Coffee disease detection using a robust HSV color-based segmentation and transfer learning for use on smartphones,” International Journal of Intelligent Systems, vol. 37, no. 8, pp. 4967–4993, 2022, doi: 10.1002/int.22747.